

데이터 분석 과제 전형 | 제출 자료

서울 다세대(빌라) AI 시세 산정 모델

지번·층·호를 넣으면 시세·범위·신뢰도·근거를 산출합니다 | 강서구 화곡동 · 관악구 · 강남구 | 기준일 2026-10-06

지원자 김인석

github.com/KimInSeok-DA/DA_Seoul_Villa_AVM

공시가격에서 출발해 건물 특징으로 보정했습니다

검증 결과, 추정값은 실제 거래가와 보통 9% 차이가 났고 10건 중 8건이 $\pm 20\%$ 안에 들었습니다

9%

실제 가격과의 보통 차이

79%

실제 가격 $\pm 20\%$ 안에 든 비율(10건 중 8건)

86%

신뢰도 0.8 초과 물건의 $\pm 20\%$ 적중률

20초

20건 계산(기준 30분 이내)

1 데이터 수집

6년 치 실거래에서 이상 거래를 제외하고 최근 3년 1만 4천 건 사용

2 기본 추정

공시가격 $\times$ 그 동네의 실거래 배율

3 머신러닝 보정

연식·층·승강기·위치 등 공시가격이 덜 반영한 요인

4 범위·신뢰도 계산

과거 오차로 가격 범위와 신뢰도 산출

크게 빗나간 경우는 대부분 가족 간 거래나 급매처럼 시세와 다른 가격에 거래된 집이었습니다. 이런 사정은 주소만으로는 알 수 없어 한계로 정리했고, 지하층·노후 건물처럼 미리 알 수 있는 위험은 신뢰도를 낮춰 표시합니다.

자료를 읽는 데 필요한 숫자 네 가지

예시: 화곡동 빌라 한 채를 넣으면 추정 2.41억, 범위 1.99억~2.84억, 신뢰도 0.83이 나옵니다



오차율

추정값이 실제 거래가와 몇 %
다른지를 나타냅니다. 여러 건의
가운데 값(중앙값)을 썼고, 이
모델은 약 9%입니다

±20% 적중률

추정값이 실제 가격의 ±20%
안에 든 비율입니다. 3억 원짜리
집이면 2.4억~3.6억이고, 이
모델은 10건 중 8건입니다

80% 범위

위 막대의 하한~상한입니다.
실제 가격이 10번 중 8번
들어오도록 계산했고, 검증에서는
77~83%였습니다

신뢰도(0~1)

추정이 ±20% 안에 들
가능성입니다. 0.8이면 비슷한
물건 10건 중 8건이 맞았다는
뜻이며, 낮을수록 주의가
필요합니다

8가지 항목 순서로 구성했습니다

오른쪽 숫자는 해당 장 번호입니다. 기술 상세는 부록(24~30장)에 정리했습니다

01

기술 스택

언어·라이브러리·모델·AI 도구·API

5

05

자체 검증

632개 건물 검증, 신뢰도, 잘 맞힌·빚나간 사례

13~16

02

데이터 소스

출처·수집 방식·건수, 정제 방법

6~7

06

예시 산출

3건의 입력·출력·근거, 실제 실행 화면

17~18

03

시세 요인

사용한 변수와 제외한 변수, 그 이유

8~10

07

AI 활용

단계별 역할, AI 오류와 확인 방법

19~20

04

모델 설계

흐름도, 13가지 방법 비교

11~12

08

한계와 개선안

개선 방향

21

Python으로 수집부터 추정까지 구현했습니다

데이터는 공공데이터포털·VWorld 등 공공 API에서 직접 수집했습니다(버전·출처 상세는 부록 B)

언어

Python

수집·분석·실행을 한 언어로

데이터 처리

pandas · numpy

표 데이터 결합과 정제

머신러닝

XGBoost · scikit-learn

여러 방법 비교 후 최종 모델 선정

공공 데이터

공공데이터포털·VWorld

실거래가, 공시가격, 건축물대장, 좌표

시각화·기록

Jupyter·matplotlib·Git

분석 노트북, 그래프, 작업 이력 공개

AI 도구

Claude Code

코드 작성·점검·문서화 보조(7번 항목)

공공 데이터 **8가지**를 주소(지번) 기준으로 연결했습니다

데이터마다 얻을 수 있는 정보입니다. 다세대와 연립을 모두 포함했습니다(건수·기간 상세는 부록 B)

실거래가

실제 거래 가격

2020-10 ~ 2026-10 매매 36,997건

공시가격

정부가 매긴 호별 가격

2026년, 107,236호

건축물대장(현행·말소)

사용승인일·승강기·층수, 철거 여부

9,928개 지번 + 말소 49,074건

필지 좌표·땅값

위치 좌표와 m²당 공시지가

3개 구 123,615필지

지하철역

가장 가까운 역까지 거리

275개 역

법정동·행정동 코드

주소를 고유번호(PNU)로 변환

30개 법정동, 행정동 63개 연결

좌표는 지도 서비스(Kakao 등) 대신 정부 연속지적도에서 받았습니다. 지도 서비스는 약관상 결과를 저장할 수 없기 때문입니다.

이상 거래를 제외하고 **최근 3년** 거래로 학습했습니다

계약 취소, 시세와 동떨어진 가격(가족 간 거래 등), 철거된 옛 건물의 거래를 걸러 냈습니다

36,997

받은 매매 거래

-2,188

계약이 취소된 거래

-331

공시가격보다 지나치게 낮은 거래
(가족 간 거래 등으로 추정)

-1,115


철거된 옛 건물의 거래,
여러 호를 한꺼번에 판 거래

33,363

정제 후 거래

14,401



학습에 쓴 최근 3년



- 거래량은 2021년에 가장 많았고 2023년까지 크게 줄었습니다. 시장 상황이 달라 오래된 거래는 현재 시세와 잘 맞지 않습니다
- 학습 기간 3년·5년·6년을 같은 방식으로 검증한 결과, 최근 3년이 가장 정확했습니다(처음 보는 건물 기준 적중 10건 중 7.5건 → 8건)

공시가격 하나로 실제 가격 차이의 87%를 설명할 수 있습니다

그래서 공시가격을 추정의 출발점으로 삼았습니다. 실거래가는 보통 공시가격의 1.76배입니다





- 왼쪽: 점 하나가 거래 1건입니다. 공시가격이 높을수록 실거래가도 높아 점들이 한 줄로 모입니다
- 오른쪽: 요인별 설명력입니다. 공시가격 하나(87%)가 면적·지역·땅값·연식·역·층을 모두 합친 것(72%)보다 큼니다
- 공시가격은 정부가 위치·면적·층·연식을 따져 호마다 매긴 가격이라 이미 많은 정보를 담고 있습니다

공시가격이 덜 반영하는 요인: 노후 건물과 저층



공시가격이 같아도 노후 건물·지하·1층은 공시가격 대비 더 높게 거래됩니다. 이 차이를 머신러닝으로 보정했습니다

연식 — 새 건물이 m²당 비싸지만, 공시 대비 비율은 오래된 건물이 더 높다(공시가격이 노후 건물 시세를 덜 반영)



- 왼쪽 그래프: 새 건물일수록 m²당 가격이 높습니다
- 오른쪽 그래프: 그러나 '실거래가 ÷ 공시가격' 배율은 노후 건물이 더 높습니다(강남 1.77배 → 2.12배). 재개발 기대가 공시가격에 덜 반영된 것으로 보입니다
- 지하층의 m²당 가격은 지상의 54~59%이고, 배율은 지하·1층이 높습니다
- 이 차이를 연식·층·승강기·면적·위치 정보로 보정합니다

층 — 지하는 지상의 절반 수준, 5층 이상은 신축 고층이 많아 비싸다. 공시 대비 비율은 지하·1층이 높다



사용한 정보와 제외한 정보: 주소와 층으로 알 수 있는 것만 사용했습니다

추정 시점에 알 수 없는 정보(예: 직거래 여부)는 가격에 영향이 커도 사용할 수 없습니다

사용한 정보

- 공시가격, 동네 실거래 배율, 시기별 시세 변화
- 연식 · 층(지하·꼭대기 층 여부) · 건물 층수 · 전용면적
- 승강기 · 세대수 · 세대당 주차
- 지하철역 거리 · 땅값 · 위치(좌표) · 지역
- 머신러닝 중요도가 높은 정보: 연식 · 지역 · 층 · 건물 층수 · 면적 · 위치

제외한 정보와 이유

- 직거래 여부, 매도·매수인 정보: 추정 시점에 알 수 없음
- 전월세: 전세금은 매매가와 성격이 다름
- 건축년도: 연식과 중복 / 동 수: 세대수와 거의 중복
- 건물 구조: 90%가 철근콘크리트라 구별력이 없음
- 학교·공원 거리: 기간 내 반영하지 못함(개선안)

주소 한 줄이 **시세·범위·신뢰도·근거**가 되는 과정


실행할 때마다 최신 거래로 다시 계산하므로, 새 거래가 쌓이면 다시 실행하는 것만으로 반영됩니다



⑤의 두 값은 건물 특징만으로 직접 낸 가격과, ④가 빗나갈 정도를 예측해 고친 가격입니다. 장단점이 달라 두 값의 평균을 씁니다

13가지 방법을 같은 조건으로 비교해 가장 안정적인 방법을 선택했습니다

검증 방식: 일부 건물을 따로 떼어 두고, 나머지로 학습한 뒤 떼어 둔 건물의 실거래가를 맞췄습니다



구분	내용
후보	선형 회귀 · 비슷한 거래 평균 · 랜덤포레스트 · XGBoost × 계산 방식 3가지 + 기본 추정 = 13가지
검증 상황	① 처음 보는 건물 ② 과거 거래가 있는 건물 ③ 1년 전 모델로 1년 뒤 예측
데이터 분리	건물 단위로 분리 (같은 건물이 학습·검증에 섞이면 성적이 부풀려짐)
선정 기준	결과를 보기 전에 확정 2,000회 재표본으로 차이가 우연인지 확인
선택	XGBoost(두 방식의 평균): 세 상황 모두 상위권 랜덤포레스트 잔차 방식은 한 상황 78.8%였으나 다른 상황에서 순위가 낮음

학습에 쓰지 않은 632개 건물로 검증한 결과, 10건 중 8건이 ±20% 안에 들었습니다

최근 1년 거래가 있는 건물 3,159개 중 632개를 미리 떼어 두고, 건물마다 가장 최근 거래가를 맞혔습니다

검증 상황	보통 오차(중앙값)	±20% 안에 든 비율	실제 가격이 80% 범위 안에 든 비율
처음 보는 건물	9.4%	78.5%	82.9%
과거 거래가 있는 건물	8.6%	80.1%	80.7%
(비교) 기본 추정만 사용	11.1% / 10.7%	71.7% / 73.9%	69.8% / 67.7%

지역별 결과(과거 거래가 있는 건물): 보통 오차 · ±20% 적중

강서 화곡동

8.4% · 80%

관악구

8.3% · 84%



강남구

9.7% · 73%

처음 세운 목표(보통 오차 10% 이하, ±20% 적중 75% 이상, 범위 포함 70~90%)를 모두 달성했습니다

신뢰도가 높은 물건일수록 오차가 작았습니다

보통 오차는 신뢰도 0.6 이하 물건 17%, 0.8 초과 물건 7%이고, $\pm 20\%$ 적중률은 62%에서 86%로 높아졌습니다



가장 높은 신뢰도 0.88

174건 중 91% 적중

보통 오차 7.0% (과거 거래가 있는 건물)

- 왼쪽: 대각선 띠($\pm 20\%$) 안의 점이 많을수록 정확합니다. 632건 중 80%가 띠 안에 있습니다
- 오른쪽: 표시한 신뢰도와 실제 적중률이 거의 같습니다(0.56→62%, 0.77→77%, 0.86→86%)
- 동네 가격 편차가 크거나 소형·강남·지하층·노후 건물이면 신뢰도를 낮게 계산합니다

잘 맞힌 경우: 검증 건물의 30%는 오차 5% 이내였습니다

632건 중 192건이 실거래가 $\pm 5\%$ 안에 들었습니다. 아래는 권역별로 오차가 가장 작았던 중개거래입니다

30%

오차 5% 이내(632건 중 192건)

91%

가장 높은 신뢰도(0.88) 174건의 $\pm 20\%$ 적중률

물건	실거래가*	추정	차이	신뢰도	근거
강서 화곡동 57.31m ² 1층	2.07억	2.07억	-0.1%	0.88	같은 건물 거래, 보정 +9%
강서 화곡동 23.59m ² 4층	2.01억	2.01억	+0.1%	0.83	같은 건물 거래 3건, 보정 -6%
관악 신림동 59.93m ² 4층	3.60억	3.60억	0.0%	0.83	같은 건물 거래 없이 동네 비율만
관악 봉천동 45.13m ² 2층	3.01억	3.01억	-0.1%	0.88	같은 건물 거래, 보정 -3%
강남 청담동 90.12m ² 1층	19.11억	19.18억	+0.4%	0.58	기본 추정 15.6억, 보정 +23%
강남 개포동 54.55m ² 3층	6.74억	6.78억	+0.6%	0.69	동네 비율, 보정 +4%

- 같은 건물의 최근 거래나 거래가 많은 동네의 비율이 있으면 기본 추정이 안정적이었습니다
- 청담동 19억 원대 주택은 기본 추정(15.6억)이 낮았지만, 머신러닝 보정이 23% 올려 0.4% 차이로 맞혔습니다
- 잘 맞은 물건이라도 강남·노후 조건이면 신뢰도를 낮게 표시합니다. 신뢰도는 결과가 아니라 조건으로 정해집니다

크게 빗나간 경우는 대부분 시세와 다른 가격에 거래된 집이었습니다

가족 간 거래나 급매처럼 사정이 있는 거래는 주소만으로 알 수 없어 모델의 한계로 정리했습니다

78%

±20%를 벗어난 126건 중 공시가격 대비
유난히 싸거나 비싸게 거래된 비율

11 / 15

오차가 가장 큰 15건 중 직거래

물건	실거래가*	추정	차이	추정 원인
강남 대치동 24.67m ² 5층	1.80억	3.87억	+115%	공시가격과 거의 같은 값에 거래
강남 청담동 37.2m ² 2층	3.89억	7.41억	+91%	직거래, 공시가격보다 싸게
관악 봉천동 60.09m ² 3층	2.10억	3.82억	+82%	직거래
관악 봉천동 68.67m ² 1층	1.84억	3.32억	+80%	직거래, 34년 된 건물
강서 화곡동 30.00m ² 7층	1.24억	2.19억	+76%	직거래, 공시가격보다 싸게

- 직거래(검증 대상의 10%)는 보통 오차가 22%입니다. 거래 당사자 간 사정이 가격에 반영된 것으로 보입니다
- 지하층·노후 건물은 미리 알 수 있어 신뢰도를 낮춰 표시합니다
- 비싼 집은 조금 낮게, 싼 집은 조금 높게 추정하는 경향이 있습니다(강남이 보통 5% 낮게 나오는 이유)

권역별 예시 3건: 호 입력, 면적 빈칸, 지하층

강서구 화곡동·관악구·강남구에서 1건씩, 입력 조건을 다르게 골라 실제 출력을 옮겼습니다

강서 화곡동 354-41

2층 203호 · 34.01m²

2.41억

80% 범위 1.99 ~ 2.84억

신뢰도 0.83

근거

공시가격 1.34억 × 실거래 배율 1.78(같은 건물 거래 2건 + 동네) = 2.38억, 건물 특징 보정 +1%

참고: 이 집의 최근 실거래를 빼고 계산했을 때 오차 -13.4%

관악 봉천동 898-9

3층 · 면적 빈칸

2.45억

80% 범위 2.04 ~ 2.95억

신뢰도 0.83

근거

공시가격 1.28억 × 배율 1.88 = 2.40억, 보정 +2%. 빈 면적은 공시가격 자료(39.76m²)로 채움

참고: 이 집의 최근 실거래를 빼고 계산했을 때 오차 +6.3%

강남 일원동 661-1

지하 1층 · 49.08m²

5.45억

80% 범위 4.00 ~ 7.95억

신뢰도 0.58

근거

공시가격 2.05억 × 배율 2.42 = 4.96억, 보정 +10%. 지하·강남이라 신뢰도가 낮고 범위가 넓음

참고: 이 집의 최근 실거래를 빼고 계산했을 때 오차 -13.7%

과제 명령 한 줄로 실행하며, 잘못된 입력은 사유를 남기고 넘어갑니다

앞 장의 3건에 행정동 입력 1건과 잘못된 입력 6건을 섞어 실제로 실행한 화면입니다

```

AVM-demo
(.venv) PS C:\DA_WorkSpace\DA_Seoul_Villa_AVM> type input.csv
id,sigungu,dong,jibun,floor,ho,area_m2
1,서울특별시 강서구,화곡동,354-41,2,203,34.01
2,서울특별시 관악구,봉천동,898-9,3,,
3,서울특별시 강남구,일원동,661-1,-1,,49.08
4,서울특별시 관악구,낙성대동,41-111,3,,35.64
5,서울특별시 마포구,합정동,100-1,2,201,40
6,서울특별시 강서구,등촌동,654-40,2,,50
7,서울특별시 관악구,없는동,1-1,1,,30
8,서울특별시 관악구,봉천동,abc,1,,30
9,서울특별시 강남구,역삼동,9999-99,2,,40
10,서울특별시 관악구,봉천동,898-9,옥탑,,

(.venv) PS C:\DA_WorkSpace\DA_Seoul_Villa_AVM> python predict.py --input input.csv --output output.csv
10건 처리(ok 4, fail 6), 12.9초 → output.csv

(.venv) PS C:\DA_WorkSpace\DA_Seoul_Villa_AVM> Import-Csv output.csv | where status -eq ok | ft id, price_est, confidence, status

id price_est confidence status
--
1 240630000 0.83 ok
2 244960000 0.83 ok
3 544690000 0.58 ok
4 246540000 0.64 ok

(.venv) PS C:\DA_WorkSpace\DA_Seoul_Villa_AVM> Import-Csv output.csv | where status -eq fail | ft id, status, basis

id status basis
--
5 fail 권역 밖(서울특별시 마포구)
6 fail 권역 밖(강서구는 화곡동만, 입력 등촌동)
7 fail 주소 해석 불가(동 '없는동'이 관악구의 법정동·행정동에 없음)
8 fail 주소 해석 불가(지번 'abc')
9 fail 주소 해석 불가(지번 9999-99 필지 없음)
10 fail 층 해석 불가('옥탑')

```

실패 사유(basis)	입력 예
권역 밖	다른 구(마포구), 강서구의 화곡동 외 동
주소 해석 불가: 동	없는 동 이름
주소 해석 불가: 지번	숫자가 아닌 지번(abc)
주소 해석 불가: 필지 없음	존재하지 않는 지번(9999-99)
층 해석 불가	'옥탑'처럼 숫자가 아닌 층

- 1~3번은 앞 장 예시와 같은 결과이고, 4번은 행정동 이름(낙성대동)을 법정동으로 바꿔 처리했습니다
- 실패 행도 출력 파일에 입력과 같은 순서로 남아 입력과 1:1로 대응합니다
- 값을 임의로 만들거나 실행이 멈추지 않습니다

코드는 AI와 함께 작성했고, 방향과 검증은 제가 판단했습니다

사용한 AI 도구는 Claude Code이며, 단계마다 역할을 나눠 활용했습니다

AI 작업 규칙을 문서로 관리

- 수치는 실제 실행 결과만 사용, 데이터 결합 때마다 건수 대조, 상용 시세 사용 금지
- 결정마다 선택지와 근거를 기록(24건)
- 작업 이력을 매일 기록해 다음 날 이어서 진행
- AI 결과는 직접 확인한 뒤 반영(PR 20건)

단계	AI가 한 일	제가 판단·결정한 것
설계	과제 요약, 감정평가 방식을 모델에 연결	마감·기준일 해석, 같은 호의 과거 거래 활용 방식
수집	정부 API 응답 확인, 수집 코드	수집 범위 결정, 약관 문제 데이터 교체
다듬기	중복·표기·이상한 거래를 걸러 내는 규칙	제외 기준(낮은 이상치만 제외)
모델	검증 설계, 13가지 방법 비교, 신뢰도 계산	여러 모델 비교 요구, 최종 모델·학습 3년 결정
점검	데이터 전수 점검, 문서와 코드 대조	단계별 재검증 요청
문서	결정 기록·그림·발표 자료 초안	공개 범위 결정, 최종 검토

AI의 오류는 결과를 직접 확인하는 단계에서 찾았습니다

AI의 결과를 그대로 쓰지 않고, 실행 결과·원본 데이터·과제 원문과 대조하는 단계를 따로 두었습니다

확인 방법	AI의 오류	조치
과제 원문·약관 확인	지하철역 위치를 저장 금지 서비스(Kakao)에서 받아 저장	정부 공공데이터로 교체
과제 원문·약관 확인	'모은 데이터에 없는 집은 그 자리에서 조회' 요구를 놓침	실행 중 조회 기능 추가
숫자 범위 점검	정상 거래의 26%를 이상한 거래로 잘못 표시	기준을 고쳐 0.4%로
숫자 범위 점검	건물 사용승인일을 잘못 읽어 연식이 2006년	코드 수정
직접 실행	호수를 비교하는 버그로 20건 중 18건 오류	코드와 검사 방법 수정
하나씩 열어 보기	정상 거래 133건까지 '묶음 거래'로 잘못 분류	확인 후 12건만
숫자 대조	데이터를 보기 전에 쓴 그림 제목 6개가 실제와 다름	결과 표와 맞춰 수정
직접 질문	근거 없이 '3년 치만 수집'을 제안	6년 수집 후 검증으로 3년 결정
과제 명령으로 실행	엑셀로 저장한 입력 파일(CP949)을 못 읽어 전체가 멈춤	두 인코딩 모두 읽기, 시험 파일 추가
직접 질문	상용 시세 비교값을 약관 확인 없이 공개 저장소에 넣음	약관 확인 후 요약만 공개

배운 점

확인 단계를 따로 둘 때만 오류가 드러났습니다. 그래서 단계마다 점검을 요청했습니다

AI 없이 했다면 약 2.5~3.5개월

파이썬 5개월 차 기준 · 같은 범위 · 실제 소요 3일

- 공공 API·데이터 처리·검증 방법을 익히는 시간이 대부분
- 범위를 줄여도(방법 1개, 단순 신뢰도) 5~6주
- AI는 구현 시간을 줄였고, 선택과 검증은 직접 했습니다

남은 과제는 **사정이 있는 거래**와 호 단위 정보입니다

더 개선하기 위해서는 데이터 자동 갱신과 성능의 지속적인 재검증이 필요합니다

한계

- 가족 간 거래·급매는 구별하지 못하고 신뢰도에도 반영하지 못함
- 비싼 집은 조금 낮게, 싼 집은 조금 높게 추정하는 경향
- 강남 안에서는 위험 물건을 신뢰도로 충분히 구분하지 못함
- 실거래 자료에 호 정보가 없어, 호까지 넣은 입력의 정확도는 검증하지 못함
- 공시가격이 없는 집은 정확도가 낮아 신뢰도를 0.10으로 표시
- 갱신하지 않으면 1년 뒤 3~5% 낮게 추정
- 시세 흐름은 3개월 평균이라 반응이 늦고, 신고가 덜 들어온 최근 2개월(9·10월)은 반영하지 못함

개선안

- 실거래가는 매월, 공시가격은 매년 자동 수집
- 새 거래로 매월 성능을 재측정하고, 기준 미달 시 재학습
- 사정이 있는 거래를 걸러 낼 추가 자료(등기부 등)
- 호 단위 정보(방향·조망·내부 상태), 학교·공원·상권 거리
- 주변 유사 거래를 근거로 함께 제시
- 모델을 미리 학습해 두고 요청마다 즉시 응답

정리

- 공시가격에서 출발해 단순하고 설명하기 쉬운 추정을 만들었습니다(가격 차이의 87% 설명)
- 공시가격이 덜 반영한 노후도·층·위치 차이를 머신러닝으로 보정해 오차를 줄였습니다(11% → 9%)
- 과거 오차로 신뢰도를 계산해, 표시한 신뢰도와 실제 적중률이 거의 같습니다
- 권역 밖이거나 해석할 수 없는 주소도 멈추지 않고, 해당 행에 실패 사유를 남깁니다

9%

실제 가격과의 보통 차이

79%

실제 가격 $\pm 20\%$ 안(10건 중 8건)

86%

신뢰도 0.8 초과 물건의 $\pm 20\%$ 적중률

0건

표본 20건 실행 실패

부록

기술 상세

용어 풀이 · 기술 스택과 데이터 상세 · 검증 상세표 · 모델 비교 방법 · 신뢰도 계산 방법 · 시점 지수 검증 · 하우스머치 참고 비교

용어 풀이

용어	뜻
B1(기본 추정)	공시가격 × 실거래/공시 비율. 비율은 같은 건물 → 법정동 → 구 순서로 가져오고, 거래가 적으면 동네 값 쪽으로 조정
시점 지수(시점 보정)	구별·월별 실거래/공시 비율의 중앙값(3개월 이동평균). 과거 거래가를 기준일 가격으로 환산
XGBoost	결정 나무를 여러 개 이어 붙여 앞 나무의 오차를 다음 나무가 줄이는 머신러닝 방법(그래디언트 부스팅)
직접 / 잔차 / 평균	직접: 건물 특징으로 $\log m^2$ 당 가격 예측 / 잔차: $\log(\text{실거래} \div B1)$ 예측해 B1을 보정 / 평균: 두 추정의 기하평균
PNU(지번)	법정동코드 10자리 + 산 여부 1자리 + 본번 4자리 + 부번 4자리. 데이터를 합치는 열쇠
홀드아웃	학습에 쓰지 않고 검증용으로 떼어 둔 표본(건물 632개)
GroupKFold	교차검증을 건물(그룹) 단위로 나눠 같은 건물이 학습·검증에 섞이지 않게 함
그리드서치	하이퍼파라미터(나무 깊이·개수 등) 조합을 모두 시험해 교차검증 성적이 가장 좋은 것을 고름
부트스트랩	표본을 복원 추출로 2,000번 다시 뽑아 성적 차이의 95% 구간을 구함. 0을 포함하지 않으면 우연이 아니라고 판단
MAPE / 중앙값 오차율	$ \text{추정} - \text{실제} \div \text{실제의 평균} / \text{중앙값}$
수정 Z-점수	중앙값과 MAD로 계산한 이상치 점수. $ z > 3.5$ 를 이상치로 봄(Iglewicz & Hoaglin 1993)
결정계수 / VIF	결정계수: 변수가 설명하는 분산 비율 / VIF: 변수끼리 얼마나 겹치는지(다중공선성)

기술 스택과 데이터 상세

구분	사용
언어·환경	Python 3.12+ (개발 3.14.5), uv + requirements.txt, 3.12·3.13·3.14 새 환경에서 같은 출력 확인
라이브러리	pandas 3.0.6, numpy 2.5.3, XGBoost 3.4.1, scikit-learn 1.9.1, requests, python-dotenv, Jupyter, matplotlib
API 키	DATA_GO_KR_API_KEY(실거래·건축물대장), VWORLD_API_KEY(공시가격·연속지적도), SEOUL_OPEN_API_KEY(폐쇄말소대장)·REB_API_KEY(부동산원 지수, 검증용). 환경변수로 받으며 predict.py는 키 없이도 실행

데이터	수집 방식	기간·기준	받은 건수	정제 후 · 사용
연립다세대 매매 실거래	API, 구·월별 전수	2020-10~2026-10	36,997건	33,363건 · 학습 최근 3년 14,401건
연립다세대 전월세	API	2020-10~2026-10	143,109건	사용 안 함
공동주택가격(호별)	API, 거래 지번마다	2026(없으면 최근 연도)	9,928개 지번	107,236호
건축물대장 표제부	API, 거래 지번마다	수집일 현행	9,928개 지번	연식·승강기·층수·세대수·주차
필지 좌표·공시지가	API(연속지적도), 3개 구 전체	2025 공시지가	123,615필지	좌표·땅값·역 거리
지하철역	공공데이터 파일	2026-06-30	367개	275개 역
법정동코드·행정동 연계	공공데이터·행정안전부 파일	2026-06-30 · 2026-09-30	—	30개 법정동 · 63개 행정동
폐쇄말소대장 표제부	API(서울 열린데이터광장), 서울 전체	수집일 기준	383,716건	3개 구 49,074지번 · 철거 전 거래 523건 제외
부동산원 연립/다세대 매매 지수	API(R-ONE)	월간	873행	시점 지수 검증에만(부록 F)

유형: 다세대 30,135 · 연립 3,097 · 혼합 표기 131건(정제 후). 정제: 해제 2,188 · 낮은 이상치(수정 $Z < -3.5$) 331 · 일괄 매매 합계 12 · 재건축 전 580 · 철거된 건물 523 제외

자체 검증 상세(632개 건물, 입력: 호 없음)

상황	면적	중앙값 오차	MAPE	±10% 적중	±20% 적중	80% 구간 포함
A 처음 보는 건물	있음	9.4%	13.7%	52.7%	78.5%	82.9%
A 처음 보는 건물	비움	11.0%	16.2%	46.4%	73.3%	80.1%
B 같은 건물 과거 거래 있음	있음	8.6%	13.0%	55.7%	80.1%	80.7%
B 같은 건물 과거 거래 있음	비움	10.5%	15.6%	48.6%	74.1%	77.2%
기준선 B1 (A / B)	있음	11.1% / 10.7%	15.8% / 14.7%	45.3% / 48.1%	71.7% / 73.9%	69.8% / 67.7%

신뢰도 구간	A 표본 / 평균 신뢰도 / 실제 ±20% 적중	B 표본 / 평균 신뢰도 / 실제 ±20% 적중
0.6 이하	73 / 0.57 / 58.9%	47 / 0.56 / 61.7%
0.6~0.7	120 / 0.67 / 70.8%	94 / 0.66 / 70.2%
0.7~0.8	171 / 0.77 / 77.2%	137 / 0.77 / 77.4%
0.8 초과	268 / 0.84 / 88.1%	354 / 0.86 / 86.2%

분할: 최근 12개월 거래가 있는 평가 권역 건물 3,159개 중 20%(시드 42)를 건물 단위로 분리, 건물마다 최근 거래 1건. A는 그 건물 거래를 모두 빼고, B는 대상 거래 이전 거래만 남김. 구간·신뢰도 보정은 나머지 건물 1만 건으로


모델 비교 방법과 학습 기간

- 후보 13개: Ridge · KNN · 랜덤포레스트 · XGBoost × {직접(log m²당 가격) / 잔차(log 실거래÷B1) / 둘의 기하평균} + B1
- Pipeline(결측 채움·표준화 → 모델) + GridSearchCV, 학습 세트 안에서만 GroupKFold(5, 그룹 = PNU), 기준 MAE(log)
- 누수 방지: 학습 행의 B1 근거는 그 거래보다 앞선 같은 건물 거래와 자기 건물을 뺀 동네 통계로만 계산
- 상황 A(처음 보는 건물) · B(같은 건물 앞선 거래 있음) · T(2025-08까지 학습해 그 뒤 1년 맞히기)
- 선정 기준(±20% 적중·중앙값 오차·MAPE, 세 상황 순위, 부트스트랩 95% 구간, 단순성)을 결과 전에 문서로 고정
- 결과: XGB-평균이 평균 순위 1위(1.8), 가장 나쁜 순위 기준으로도 1위(2.3). 직접 방식은 T에서, 잔차 방식은 A에서 약해 둘의 평균을 채택

학습 기간	학습 거래	A ±20% / 중앙값	B ±20% / 중앙값
3년(채택)	14,520	79.0% / 9.3%	80.2% / 9.0%
5년	24,531	79.0% / 9.7%	78.5% / 9.3%
6년	33,886	74.5% / 9.9%	78.2% / 9.5%


3년 - 6년: A ±20% 적중 +4.4%p [+2.2, +6.8], 평균 오차 A -1.1%p · B -0.9%p(부트스트랩 95% 구간). 최종 검증과 분리한 보정 표본에서도 같은 방향(72.5% → 75.9%)

80% 구간과 신뢰도 계산 방법



항목	계산	설명
로그 오차	$e = \log(\text{추정} \div \text{실제})$	0이면 정확, +면 높게, -면 낮게 추정
오차 점수	점수 = $\sum \text{계수} \times \text{변수}$ ($ e $ 를 최소제곱 회귀)	변수: 동네·같은 건물 비율의 흠여짐, 같은 건물 거래 수, 면적, 강남·화곡, 면적 빈칸, XGBoost 두 추정의 차이, 보정 배율, 지하층, 30년 초과
80% 범위	하한 = $\text{추정} \div \exp(q_{90})$, 상한 = $\text{추정} \div \exp(q_{10})$	$q_{10} \cdot q_{90}$ = 그 구간 로그 오차의 10%·90% 분위수(정규분포 가정 없음)
신뢰도	그 구간에서 $ \text{추정} \div \text{실제} - 1 \leq 0.2$ 인 비율	점수가 클수록 낮아지도록 단조 보정(isotonic)
예외	공시가격 없음 → 신뢰도 0.10 고정	보정 표본이 20건뿐이라 별도 처리. 수집에 없는 지번은 실행 중 공공 API 조회

직접 만든 시점 지수를 한국부동산원 지표와 비교



최근 3년(모델 학습 기간)	비교 대상	수준 상관	3개월 변화 같은 방향	3년 변화(우리 / 부동산원)
강서구	서남권(주택가격동향조사)	0.72	56%	+2.7% / +10.8%
관악구	서남권(주택가격동향조사)	0.92	69%	+8.9% / +10.8%
강남구	동남권(주택가격동향조사)	0.90	72%	+13.1% / +15.9%

하우스머치 참고 비교 9건(입력·학습에는 사용하지 않음)

	우리	하우스머치
보통 오차(중앙값): 9건 / 중개거래 7건	11.1% / 9.9%	5.6% / 4.8%
실거래가 ±20% 안 (9건)	6건	7건
실거래가가 범위 안 (9건)	7건 (80% 구간)	3건 (상하한시세)

주소	거래	실거래가	우리 추정 (신뢰도)	우리 오차
화곡동 362-79 6층	중개 2026-09	2.15억	2.04억 (0.83)	-5.0%
화곡동 811-9 1층	중개 2026-06	2.60억	2.31억 (0.78)	-11.1%
화곡동 1016-19 4층	중개 2026-08	2.70억	2.97억 (0.69)	+9.9%
봉천동 218-42 1층	중개 2026-08	6.35억	5.93억 (0.88)	-6.6%
신림동 98-242 3층	직거래 2026-05	1.20억	1.86억 (0.78)	+55.0%
신림동 409-184 3층	중개 2026-07	3.75억	3.34억 (0.64)	-11.1%
개포동 1195-3 3층	중개 2026-08	5.78억	5.37억 (0.86)	-7.0%
청담동 69-19 2층	직거래 2026-04	3.87억	7.41억 (0.74)	+91.4%
역삼동 751-8 5층	중개 2026-01	5.20억	6.41억 (0.58)	+23.3%

- 이 9건에서는 하우스머치가 실거래가에 더 가까웠습니다
- 조건 차이: 우리 값은 해당 거래를 빼고 낸 추정입니다.
하우스머치는 9건 중 8건이 추정 기준일(09-01) 이전 거래이고, 화면을 저장한 811-9는 그 거래가 거래사례 목록에 있었습니다
- 기준일 이후 거래(첫 줄)도 하우스머치가 더 가까웠습니다
- 직거래 2건은 둘 다 높게 추정했고, 우리 오차가 더 컸습니다
- 우리 신뢰도가 가장 낮았던 역삼동(0.58)이 중개거래 중 오차가 가장 컸습니다