

데이터 분석 과제 전형 | 제출 자료 요약본

서울 다세대(빌라) AI 시세 산정 모델

지번·층·호를 넣으면 시세·범위·신뢰도·근거를 산출합니다 | 강서구 화곡동 · 관악구 · 강남구 | 기준일 2026-10-06(과제 안내일)

9%

실제 가격과의 보통 오차

79%

실제 가격 $\pm 20\%$ 안

86%

신뢰도 0.8 초과 물건 적중률

0건

표본 20건 실행 실패

지원자 김인석

github.com/KimInSeok-DA/DA_Seoul_Villa_AVM

Python으로 수집부터 추정까지 구현했습니다

데이터는 공공데이터포털·VWorld 등 공공 API에서 직접 수집했습니다

언어

Python

수집·분석·실행을 한 언어로

데이터 처리

pandas · numpy

표 데이터 결합과 정제

머신러닝

XGBoost · scikit-learn

여러 방법 비교 후 최종 모델 선정

공공 데이터

공공데이터포털·VWorld

실거래가, 공시가격, 건축물대장, 좌표

시각화·기록

Jupyter·matplotlib·Git

분석 노트북, 그래프, 작업 이력 공개

AI 도구

Claude Code

코드 작성·점검·문서화 보조(7번 항목)

공공 데이터 **8가지**를 주소(지번) 기준으로 연결했습니다

건축물대장은 현행·말소, 코드는 법정동·행정동 각 2종이라 카드 6장에 8가지입니다. 다세대와 연립을 모두 포함했습니다

실거래가

실제 거래 가격

2020-10 ~ 2026-10 매매 36,997건

공시가격

정부가 매긴 호별 가격

2026년, 107,236호

건축물대장(현행·말소)

사용승인일·승강기·층수, 철거 여부

9,928개 지번 + 말소 49,074지번

필지 좌표·땅값

위치 좌표와 m²당 공시지가

3개 구 123,615필지

지하철역

가장 가까운 역까지 거리

275개 역

법정동·행정동 코드

주소를 고유번호(PNU)로 변환

30개 법정동, 행정동 63개 연결

좌표는 지도 서비스(Kakao 등) 대신 정부 연속지적도에서 받았습니다. 지도 서비스는 약관상 결과를 저장할 수 없기 때문입니다.

사용한 정보와 제외한 정보: 주소와 층으로 알 수 있는 것만 사용했습니다

추정 시점에 알 수 없는 정보(예: 직거래 여부)는 가격에 영향이 커도 사용할 수 없습니다

사용한 정보

- 공시가격, 동네 실거래 배율, 시기별 시세 변화
- 연식 · 층(지하·꼭대기 층 여부) · 건물 층수 · 전용면적
- 승강기 · 세대수 · 세대당 주차
- 지하철역 거리 · 땅값 · 위치(좌표) · 지역
- 머신러닝 중요도가 높은 정보: 연식 · 지역 · 층 · 건물 층수 · 면적 · 위치

제외한 정보와 이유

- 직거래 여부, 매도·매수인 정보: 추정 시점에 알 수 없음
- 전월세: 전세금은 매매가와 성격이 다름
- 건축년도: 연식과 중복 / 동 수: 세대수와 거의 중복
- 건물 구조: 90%가 철근콘크리트라 구별력이 없음
- 학교·공원 거리: 기간 내 반영하지 못함(개선안)

주소 한 줄이 **시세·범위·신뢰도·근거**가 되는 과정

실행할 때마다 저장된 거래로 다시 계산하므로, 새 거래를 정제 데이터에 추가하고 다시 실행하면 반영됩니다



⑥의 두 값은 건물 특징만으로 직접 낸 가격과, ④가 빗나갈 정도를 예측해 고친 가격입니다. 장단점이 달라 두 값의 평균을 씁니다

학습에 쓰지 않은 632개 건물로 검증: 보통 오차 9%, 10건 중 8건이 ±20% 안

최근 1년 거래가 있는 건물 3,159개 중 632개를 미리 떼어 두고, 건물마다 가장 최근 거래가를 맞혔습니다

검증 상황(632건)	보통 오차(중앙값)	MAPE	±20% 적중	80% 범위 포함
처음 보는 건물	9.4%	13.7%	78.5%	82.9%
과거 거래가 있는 건물	8.6%	13.0%	80.1%	80.7%
(비교) 기본 추정만 사용	11.1% / 10.7%	15.8% / 14.7%	71.7% / 73.9%	69.8% / 67.7%

신뢰도가 높을수록 오차가 작음

보통 오차 17% → 7%

신뢰도 0.6 이하 → 0.8 초과, ±20% 적중 62% → 86%

오차가 컸던 사례와 원인

물건	실거래가*	추정	차이	추정 원인
강남 청담동 37.2m ² 2층	3.89억	7.41억	+91%	직거래, 공시가격보다 싸게
관악 봉천동 60.09m ² 3층	2.10억	3.82억	+82%	직거래
강서 화곡동 30.00m ² 7층	1.24억	2.19억	+76%	직거래, 공시가격보다 싸게

- ±20%를 벗어난 126건 중 78%가 공시가격 대비 유난히 싸거나 비싸게 거래된 집이었습니다
- 오차 상위 15건 중 11건이 직거래로, 거래 사정은 주소만으로 알 수 없어 한계로 정리했습니다

* 기준일 환산 실거래가 · 면적 입력 기준, 비교 행은 처음 보는 건물 / 과거 거래가 있는 건물 · 상세는 본편 13~16장과 부록 C

권역별 예시 3건: 호 입력, 면적 빈칸, 지하층

강서구 화곡동·관악구·강남구에서 1건씩, 입력 조건을 다르게 골라 실제 출력을 옮겼습니다

강서 화곡동 354-41

2층 203호 · 34.01m²

2.41억

80% 범위 1.99 ~ 2.84억

신뢰도 0.83

근거

공시가격 1.34억 × 실거래 배율 1.78(같은 건물
거래 2건 + 동네) = 2.38억, 건물 특징 보정 +1%

참고: 이 집의 최근 실거래를 빼고 계산했을 때 오차
-13.4%

관악 봉천동 898-9

3층 · 면적 빈칸

2.45억

80% 범위 2.04 ~ 2.95억

신뢰도 0.83

근거

공시가격 1.28억 × 배율 1.88 = 2.40억, 보정 +2%.
빈 면적은 공시가격 자료(39.76m²)로 채움

참고: 이 집의 최근 실거래를 빼고 계산했을 때 오차
+6.3%

강남 일원동 661-1

지하 1층 · 49.08m²

5.45억

80% 범위 4.00 ~ 7.95억

신뢰도 0.58

근거

공시가격 2.05억 × 배율 2.42 = 4.96억, 보정
+10%. 지하·강남이라 신뢰도가 낮고 범위가 넓음

참고: 이 집의 최근 실거래를 빼고 계산했을 때 오차
-13.7%

코드는 AI와 함께 작성했고, 방향과 검증은 제가 판단했습니다

사용한 AI 도구는 Claude Code이며, AI의 결과는 실행 결과·원본 데이터·과제 원문과 대조한 뒤 반영했습니다

단계	AI가 한 일	제가 판단·결정한 것
설계	과제 요약, 감정평가 방식을 모델에 연결	마감·기준일 해석, 검증 물건의 과거 거래도 일반 비교사례로 사용(특정 물건 분기 금지)
수집	정부 API 응답 확인, 수집 코드	수집 범위 결정, 약관 문제 데이터 교체
다듬기	중복·표기·이상한 거래를 걸러 내는 규칙	제외 기준(낮은 이상치만 제외)
모델	검증 설계, 13가지 방법 비교, 신뢰도 계산	여러 모델 비교 요구, 최종 모델·학습 3년 결정
문서	결정 기록·그림·발표 자료 초안	공개 범위 결정, 최종 검토

AI의 오류	확인 방법 → 조치
지하철역 좌표를 저장 금지 서비스에서 받아 저장	약관 확인 → 공공데이터로 교체
정상 거래의 26%를 이상 거래로 잘못 표시	수치 점검 → 기준 수정(0.4%)
엑셀(CP949) 입력 파일을 못 읽어 전체가 멈춤	과제 명령으로 실행 → 두 인코딩 처리
근거 없이 '3년 치만 수집'을 제안	직접 질문 → 6년 수집 후 검증으로 3년 결정

AI 작업 규칙을 문서로 관리

- 수치는 실제 실행 결과만 사용, 데이터 결합 때마다 건수 대조
- 결정마다 선택지와 근거 기록(24건), 직접 확인 후 반영(PR 20건 이상)

AI 없이 했다면

약 2.5~3.5개월

본인 추정 · 파이썬 5개월 차 기준 · 같은 범위 · 실제 소요 3일

공공 API·데이터 처리·검증 방법을 익히는 시간이 대부분입니다.
AI는 구현 시간을 줄였고, 선택과 검증은 직접 했습니다

남은 과제는 **사정이 있는 거래**와 호 단위 정보입니다

더 개선하기 위해서는 데이터 자동 갱신과 성능의 지속적인 재검증이 필요합니다

한계

- 직거래 등 사정이 있는 거래는 구별하지 못하고 신뢰도에도 반영하지 못함
- 비싼 집은 조금 낮게, 싼 집은 조금 높게 추정하는 경향
- 강남 안에서는 위험 물건을 신뢰도로 충분히 구분하지 못함
- 실거래 자료에 호 정보가 없어, 호까지 넣은 입력의 정확도는 검증하지 못함
- 공시가격이 없는 집은 정확도가 낮아 신뢰도를 0.10으로 표시
- 갱신하지 않으면 1년 뒤 3~5% 낮게 추정
- 시세 흐름은 3개월 평균이라 반응이 늦고, 신고가 덜 들어온 최근 2개월(9·10월)은 반영하지 못함
- 하우스머치 참고 비교 9건에서는 하우스머치가 실거래가에 더 가까웠음

개선안

- 실거래가는 매월, 공시가격은 매년 자동 수집
- 새 거래로 매월 성능을 재측정하고, 기준 미달 시 재학습
- 사정이 있는 거래를 걸러 낼 추가 자료(등기부 등)
- 호 단위 정보(방향·조망·내부 상태), 학교·공원·상권 거리
- 주변 유사 거래를 근거로 함께 제시
- 모델을 미리 학습해 두고 요청마다 즉시 응답